

期末大作业实验报告

二维复杂分布生成建模的比较研究

孙悦淳 PB23000033

2026 年 6 月 10 日

摘要

本报告选择期末大作业的“二维分布生成建模”选题,研究不同生成模型在 Gaussian Mixture、Ring、Two Moons 和 Spiral 四类二维复杂分布上的建模能力。二维数据虽然维度低,但具有多峰性、闭合支撑、弯曲流形和螺旋结构等典型难点,能够直接暴露生成模型的模式覆盖、过平滑、离流形采样和评价指标不一致等问题。本文从数学建模角度将任务表述为学习未知分布 $p_c(\mathbf{x})$ 并生成新样本的问题,比较核密度估计 (KDE)、高斯混合模型 (GMM)、变分自编码器 (VAE) 和去噪扩散概率模型 (DDPM) 四类方法。

实验使用固定随机种子生成四类训练集和测试集,每类训练样本 1200 个、测试样本 900 个,并在 3 个随机种子上重复训练与采样。评价指标包括负对数似然 (NLL)、最大均值差异 (MMD)、切片 Wasserstein 距离 (SWD)、Precision、Coverage 和二维网格支撑覆盖率。结果表明,在当前二维合成数据和样本量设置下,经典密度模型是很强的基线: GMM 在 Gaussian Mixture 和 Two Moons 上取得最低 MMD, KDE 在 Ring 上取得最低 MMD 与最高 Coverage; DDPM 在 Spiral 上取得最低 MMD,说明逐步去噪机制对高度弯曲支撑具有优势,但其 Precision 仍低于 KDE/GMM。VAE 训练稳定,但在四类数据上均出现明显过平滑。本文进一步完成条件 DDPM、超参数扫描和四类模型的异常点鲁棒性实验,说明生成建模不能只依赖单一“先进模型”,而应结合数据几何结构、模型假设和多指标评价进行判断。

关键词: 生成模型; 二维分布; 核密度估计; 高斯混合模型; 变分自编码器; 扩散模型; MMD; Wasserstein 距离

目录

1	一、问题重述与研究思路	4
1.1	任务背景	4
1.2	核心问题	4
1.3	本文完成内容	4
2	二、文献与方法定位	5
2.1	经典密度估计	5
2.2	神经生成模型	5
2.3	评价指标	5
3	三、数据、假设与符号说明	5
3.1	数据生成与预处理	5
3.2	建模假设	6
3.3	符号说明	7
4	四、数学模型建立	7
4.1	核密度估计	7
4.2	高斯混合模型	7
4.3	变分自编码器	8
4.4	去噪扩散概率模型	8
5	五、评价指标	8
5.1	负对数似然	8
5.2	最大均值差异	9
5.3	切片 Wasserstein 距离	9
5.4	Precision、Coverage 与支撑覆盖率	9
6	六、实验设计与实现	9
6.1	实验设置	9
6.2	产物组织	10
7	七、实验结果	11
7.1	生成样本可视化	11

7.2	主指标对比	12
7.3	指标热力图	13
7.4	条件生成实验	13
8	八、超参数与鲁棒性分析	15
8.1	KDE 带宽与 GMM 组分数	15
8.2	异常点鲁棒性	16
9	九、讨论与局限	16
9.1	为什么经典模型表现很强	16
9.2	VAE 的过平滑现象	17
9.3	DDPM 的优势与成本	17
9.4	局限性	17
10	十、结论	17
11	十一、复现实验、分工与 AI 使用说明	19
11.1	复现实验	19
11.2	文件清单	19
11.3	分工情况	19
11.4	AI 使用说明	19
A	附录 A：关键实现片段	20
B	附录 B：结论验证表	20

1 一、问题重述与研究思路

1.1 任务背景

生成建模的目标是从训练样本中学习数据背后的概率分布，并从该分布中生成新的样本。与分类和回归任务不同，生成建模不仅关心单点预测是否正确，还关心生成样本是否覆盖真实分布的支撑、是否保持多样性、是否遗漏模式、是否在低密度区域产生不合理样本。

本次期末大作业给定四类二维复杂分布：Gaussian Mixture、Ring、Two Moons 和 Spiral。设第 c 类训练数据为

$$D_c = \{\mathbf{x}_i^{(c)}\}_{i=1}^{N_c}, \quad \mathbf{x}_i^{(c)} \in \mathbb{R}^2, \quad c = 1, 2, 3, 4.$$

任务是在训练集上建立生成模型，并在测试集上评价生成质量。由于样本是二维点，模型结果可以直接可视化，这使得本题很适合分析“模型假设”和“数据几何结构”之间是否匹配。

1.2 核心问题

本文围绕一个问题展开：

不同生成模型的结构假设，分别适合哪些二维几何分布？

具体而言，Gaussian Mixture 主要考验多峰建模；Ring 考验模型是否能保持中心低密度空洞；Two Moons 考验模型是否能表示非凸且分离的弯曲支撑；Spiral 则考验模型对长程螺旋结构的表达能力。若模型只是生成“看起来像一团点”的样本，就不能说明它真正学到了分布结构。

1.3 本文完成内容

本文完成内容如下：

1. 构造四类二维分布数据集，并对其几何结构和建模难点进行分析；
2. 实现 KDE、GMM、VAE 和 DDPM 四类生成模型；
3. 使用 MMD、切片 Wasserstein 距离、Precision、Coverage、支撑覆盖率和 NLL 评价生成质量；
4. 对 KDE 带宽和 GMM 组分数进行超参数扫描；
5. 实现一个统一的条件 DDPM $p_\theta(\mathbf{x} | c)$ ，根据类别标签生成指定分布；
6. 设计异常点污染实验，比较 KDE、GMM、VAE 和 DDPM 的鲁棒性；
7. 生成完整图表、指标文件、复现脚本和运行环境清单。

2 二、文献与方法定位

2.1 经典密度估计

KDE 是一种非参数密度估计方法，通过在每个训练样本附近放置核函数来近似整体分布。它不需要假设数据来自有限个参数化分布，适合二维、小样本、可视化任务；缺点是带宽 h 对结果影响很大，过小会产生噪声尖峰，过大会抹平真实结构。GMM 则假设分布可以表示为多个高斯分布的加权和，通过 EM 算法估计参数。GMM 对多峰数据非常自然，也能通过增加组分数逼近曲线结构，但每个局部成分本质上仍是椭圆型高斯。

2.2 神经生成模型

VAE 将生成过程写成潜变量模型，利用编码器和解码器最大化证据下界 (ELBO) [1]。它提供了清晰的概率建模解释，也易于训练；但标准高斯先验与均方重构损失容易导致过平滑，特别是在真实分布位于低维弯曲流形附近时。

DDPM 通过逐步加噪和逐步去噪学习生成过程 [2, 3]。与一次性从潜变量解码不同，扩散模型将复杂生成过程拆成许多小的去噪步骤，因此在图像生成中表现突出。在二维问题上，它的优势是可以直观地理解为从高斯噪声逐渐收缩到目标支撑；劣势是训练和采样成本更高，且若训练不足也会出现过度扩散。

2.3 评价指标

生成模型评价不能只看单个指标。NLL 衡量模型对测试样本赋予的密度，但只适用于可计算密度的模型；MMD 来自核两样本检验 [5]，可比较两组样本的整体分布差异；Wasserstein 类距离强调从一个分布搬运到另一个分布的代价 [6]；Precision 和 Coverage 则分别描述生成样本质量和真实样本覆盖情况 [7]。本文同时使用这些指标，以避免被单一数值误导。

3 三、数据、假设与符号说明

3.1 数据生成与预处理

由于项目目录中没有发现助教提供的二维分布数据文件，本文根据题目要求使用固定机制生成四类数据，并在运行清单中记录这一点。因此，本文结论严格对应本文生成机制下的二维合成数据；若后续获得官方数据，应使用同一实验管线重新运行。每类数据包含 1200 个训练样本和 900 个测试样本。四类分布的构造如下：

- Gaussian Mixture: 由 5 个不同均值和协方差的二维高斯成分混合而成；
- Ring: 半径约为 2 的闭合圆环，并加入小幅径向和位置噪声；

- Two Moons: 使用双月牙结构并加入高斯扰动；
- Spiral: 双臂螺旋结构，半径随角度增长，并加入小幅噪声。

所有模型使用训练集均值和标准差进行标准化：

$$\tilde{\mathbf{x}} = \frac{\mathbf{x} - \boldsymbol{\mu}_{\text{train}}}{\boldsymbol{\sigma}_{\text{train}}}.$$

测试集和生成样本的评价均在标准化空间中完成，图像也使用同一坐标尺度展示。




图 1: 四类二维测试分布。Gaussian Mixture 呈现离散多峰结构；Ring 具有中心空洞；Two Moons 是两个弯曲月牙；Spiral 具有长程螺旋支撑。

3.2 建模假设

本文采用如下假设：

1. 训练样本和测试样本均独立同分布地来自未知真实分布 $p_c(\mathbf{x})$ ；
2. 四类分布之间相互独立，主实验分别为每类数据训练一个无条件模型；
3. 训练集只用于拟合模型与选择超参数，测试集只用于最终评价；

4. 生成样本数与测试样本数相同，均为 900；
5. 每个模型在随机种子 0, 1, 2 上重复运行，并报告均值和标准差。

3.3 符号说明

表 1: 主要符号说明

符号	含义	维度或取值
$\mathbf{x}$	二维样本点	$\mathbb{R}^2$
D_c	第 c 类训练样本集合	有限集合
$p_c(\mathbf{x})$	第 c 类真实数据分布	概率密度
$\hat{p}_\theta(\mathbf{x})$	模型学习到的分布	概率密度或隐式分布
$\mathbf{z}$	VAE 潜变量	$\mathbb{R}^2$
t	DDPM 扩散时间步	$1, \dots, T$
ϵ_θ	DDPM 噪声预测网络	$\mathbb{R}^2 \times \{1, \dots, T\} \rightarrow \mathbb{R}^2$
X, Y	测试样本集与生成样本集	点集

4 四、数学模型建立

4.1 核密度估计

KDE 将未知密度估计为

$$\hat{p}_h(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i),$$

其中 K_h 是带宽为 h 的高斯核。本文通过验证负对数似然选择带宽：

$$h^* = \arg \min_h \left[-\frac{1}{m} \sum_{j=1}^m \log \hat{p}_h(\mathbf{x}_j^{\text{val}}) \right].$$

KDE 的优势在于不需要训练复杂网络，并且在二维任务中样本覆盖充分时很强；劣势在于高维扩展困难，且带宽选择直接决定平滑程度。

4.2 高斯混合模型

GMM 假设

$$\hat{p}(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k), \quad \sum_{k=1}^K \pi_k = 1.$$

参数 $\{\pi_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}$ 由 EM 算法估计。组分数 K 通过 BIC 选择：

$$\text{BIC} = -2 \log L + \nu \log n,$$

其中 L 为最大似然， ν 为参数个数。BIC 惩罚模型复杂度，避免用过多高斯成分机械记忆训练样本。

4.3 变分自编码器

VAE 假设潜变量满足 $\mathbf{z} \sim \mathcal{N}(0, I)$ ，解码器给出 $p_\theta(\mathbf{x} | \mathbf{z})$ 。由于真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ 难以计算，引入编码器 $q_\phi(\mathbf{z} | \mathbf{x})$ ，最大化 ELBO：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x})} [\log p_\theta(\mathbf{x} | \mathbf{z})] - D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})).$$

实现中采用二维潜变量、两层 SiLU MLP 编码器和解码器，训练损失写为重构误差加 KL 正则：

$$\mathcal{L}_{\text{VAE}} = \|\hat{\mathbf{x}} - \mathbf{x}\|_2^2 + \beta D_{\text{KL}}.$$

4.4 去噪扩散概率模型

DDPM 的前向过程逐步向数据加入高斯噪声：

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) I),$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。训练时随机采样时间步 t 和噪声 ϵ ，构造

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon,$$

并训练网络预测噪声：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{\mathbf{x}_0, t, \epsilon} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2.$$

采样时从标准高斯噪声出发，按反向过程逐步去噪得到 $\mathbf{x}_0$ 的样本。本文使用 100 个扩散步和 2500 轮训练；该设置在 CPU 上即可运行，兼顾效果和复现成本。

5 五、评价指标

5.1 负对数似然

对显式密度模型，测试集 NLL 定义为

$$\text{NLL} = -\frac{1}{m} \sum_{j=1}^m \log \hat{p}_\theta(\mathbf{x}_j).$$

KDE 和 GMM 可直接计算 NLL。VAE 和 DDPM 的严格似然估计需要额外近似，本文不将其纳入 NLL 比较，避免不公平。

5.2 最大均值差异

MMD 衡量两组样本在再生核 Hilbert 空间中的均值嵌入差异：

$$\text{MMD}^2(X, Y) = \frac{1}{m^2} \sum_{i,j} k(x_i, x_j) + \frac{1}{n^2} \sum_{i,j} k(y_i, y_j) - \frac{2}{mn} \sum_{i,j} k(x_i, y_j).$$

本文使用 RBF 核，并用样本距离的 median heuristic 选择核宽度。MMD 越低，说明生成分布与测试分布越接近。

5.3 切片 Wasserstein 距离

二维 Wasserstein 距离可以通过多个一维投影近似。对随机方向 $\mathbf{v}$ ，先将样本投影为 $x_i^\top \mathbf{v}$ ，再计算一维排序后的平均距离；对多个方向取平均得到 SWD。SWD 越低，说明生成样本整体位置与真实样本越接近。

5.4 Precision、Coverage 与支撑覆盖率

Precision 衡量生成样本是否落在真实数据邻域中，Coverage 衡量真实样本是否被生成样本覆盖。本文用测试集第 k 近邻距离的中位数确定半径 r ，定义

$$\text{Precision} = \frac{1}{|Y|} \sum_{\mathbf{y} \in Y} \mathbb{I}(d(\mathbf{y}, X) \leq r), \quad \text{Coverage} = \frac{1}{|X|} \sum_{\mathbf{x} \in X} \mathbb{I}(d(\mathbf{x}, Y) \leq r).$$

此外，本文将测试样本所在区域划分为 36×36 的二维网格，统计真实样本占据网格中有多少也被生成样本覆盖，作为支撑覆盖率。该指标比单纯按角度或横坐标分箱更严格，因为它同时约束二维位置和局部几何支撑。

6 六、实验设计与实现

6.1 实验设置

主实验比较 KDE、GMM、VAE 和 DDPM 四类模型。每个模型在四类数据上分别训练，并在 3 个随机种子上重复。每次实验生成 900 个新样本，与 900 个测试样本进行比较。所有结果均由脚本 `final_project/src/run_experiments.py` 生成。

表 2: 模型设置

模型	关键参数	训练或选择方式	备注
KDE	带宽 h	验证 NLL 网格搜索	显式密度
GMM	组分数 K	BIC 网格搜索	显式密度
VAE	二维潜变量, MLP 编解码器	AdamW, 320 epochs	隐式采样, 近似概率模型
DDPM	100 扩散步, MLP 噪声网络	AdamW, 2500 epochs	隐式采样
条件 DDPM	100 扩散步, 类别嵌入	AdamW, 1875 epochs	统一条件生成模型

6.2 产物组织

运行后生成如下产物:

- `metrics_by_seed.csv/json`: 逐数据集、逐模型、逐 seed 指标;
- `metrics_summary.csv/json`: 均值和标准差;
- `figures/*.pdf`: 论文图表;
- `tables/*.tex`: 可直接插入报告的表格;
- `conditional_metrics_summary.csv`: 条件 DDPM 指标;
- `robustness.csv`: 异常点鲁棒性实验指标;
- `run_manifest.json`: 运行环境、随机种子、训练轮数和依赖版本。

7 七、实验结果

7.1 生成样本可视化




图 2: 四类模型在四类二维分布上的生成样本。灰色点为测试样本, 蓝色点为生成样本。KDE/GMM 在当前低维任务中是强基线; VAE 明显过平滑; DDPM 长训练后在 Spiral 上能更好跟随螺旋支撑。

图 2 直观展示了模型差异。KDE 与 GMM 在 Gaussian Mixture、Ring 和 Two Moons 上生成样本与真实样本高度重合; VAE 往往把样本填到低密度区域, 例如 Ring 的中心区域和 Two Moons 两条月牙之间; DDPM 在长训练后能改善这一问题, 并在 Spiral 上取得最低 MMD, 但其 Precision 仍低于 KDE/GMM, 说明它能覆盖整体结构, 却仍产生一定离支撑样本。因此, 本文不把 DDPM 描述为全面优于经典方法, 而是把它视作在复杂螺旋几何上更有优势的模型。

7.2 主指标对比

表 3: 四类模型在四类分布上的主指标，均为 3 个随机种子的均值 $\pm$ 标准差。NLL 只对 KDE 和 GMM 报告。

数据集	模型	MMD $\downarrow$	SWD $\downarrow$	Precision $\uparrow$	Coverage $\uparrow$	NLL $\downarrow$
Gaussian Mixture	KDE	0.0010 ± 0.0005	0.062 ± 0.013	0.920 ± 0.016	0.967 ± 0.004	1.474 ± 0.020
Gaussian Mixture	GMM	0.0009 ± 0.0006	0.058 ± 0.018	0.956 ± 0.007	0.956 ± 0.008	1.430 ± 0.017
Gaussian Mixture	VAE	0.0055 ± 0.0001	0.181 ± 0.009	0.433 ± 0.017	0.889 ± 0.016	–
Gaussian Mixture	DDPM	0.0022 ± 0.0006	0.086 ± 0.005	0.904 ± 0.004	0.956 ± 0.006	–
Ring	KDE	0.0007 ± 0.0002	0.051 ± 0.004	0.959 ± 0.011	0.989 ± 0.002	1.072 ± 0.021
Ring	GMM	0.0011 ± 0.0003	0.063 ± 0.007	0.982 ± 0.002	0.985 ± 0.006	1.034 ± 0.022
Ring	VAE	0.0107 ± 0.0005	0.176 ± 0.003	0.555 ± 0.009	0.949 ± 0.005	–
Ring	DDPM	0.0019 ± 0.0007	0.081 ± 0.012	0.953 ± 0.005	0.986 ± 0.005	–
Two Moons	KDE	0.0008 ± 0.0002	0.050 ± 0.006	0.970 ± 0.008	0.989 ± 0.005	1.310 ± 0.013
Two Moons	GMM	0.0005 ± 0.0005	0.040 ± 0.014	0.985 ± 0.005	0.987 ± 0.003	1.281 ± 0.031
Two Moons	VAE	0.0064 ± 0.0006	0.156 ± 0.002	0.436 ± 0.011	0.901 ± 0.021	–
Two Moons	DDPM	0.0014 ± 0.0015	0.062 ± 0.026	0.845 ± 0.015	0.977 ± 0.004	–
Spiral	KDE	0.0014 ± 0.0005	0.069 ± 0.008	0.983 ± 0.004	0.989 ± 0.005	2.194 ± 0.020
Spiral	GMM	0.0010 ± 0.0003	0.068 ± 0.007	0.931 ± 0.005	0.969 ± 0.005	2.474 ± 0.036
Spiral	VAE	0.0014 ± 0.0007	0.089 ± 0.016	0.814 ± 0.012	0.921 ± 0.016	–
Spiral	DDPM	0.0006 ± 0.0001	0.073 ± 0.004	0.809 ± 0.020	0.962 ± 0.004	–

表 4: 按指标选出的最佳模型

数据集	最低 MMD	最低 SWD	最高 Coverage
Gaussian Mixture	GMM	GMM	KDE
Ring	KDE	KDE	KDE
Two Moons	GMM	GMM	KDE
Spiral	DDPM	GMM	KDE

表 3 和表 4 给出定量结论。Gaussian Mixture 上，GMM 的 MMD 为 0.0009 ± 0.0006 ，略优于 KDE；这符合 GMM 的模型假设。Ring 上，KDE 的 MMD 和 SWD 最低，Coverage 达到 0.989 ± 0.002 ，说明非参数平滑密度估计在规则闭合曲线上非常有效。Two Moons 上，GMM 在 BIC 选择较多组分后可用多个局部高斯逼近月牙结构，因此取得最低 MMD 与 SWD。Spiral 上，DDPM 的 MMD 为 0.0006 ± 0.0001 ，低于 KDE、GMM 和 VAE；但从 SWD 和 Precision 看，GMM/KDE 仍有优势。这说明 DDPM 对螺旋整体分布形状有较好匹配，但局部贴合仍不稳定。

7.3 指标热力图




图 3: 每个数据集内部按 MMD 归一化后的相对排名。颜色越绿表示 MMD 越低。

图 3 说明“最佳模型”依赖数据结构。若只看 Gaussian Mixture，会认为 GMM 最合理；若看 Spiral，则 DDPM 的相对优势最明显。这支持本文的核心观点：生成建模不是简单选择最新模型，而是要分析数据几何与模型假设是否匹配。

7.4 条件生成实验

除分别为每类数据训练无条件模型外，本文还实现了一个统一的条件 DDPM。该模型在输入中加入类别嵌入，学习

$$p_{\theta}(\mathbf{x} \mid c), \quad c \in \{\text{Gaussian Mixture, Ring, Two Moons, Spiral}\}.$$

训练时将四类训练样本合并，并用类别标签控制反向去噪过程；采样时指定类别 c ，即可生成对应分布。




图 4: 统一条件 DDPM 的按类别生成结果。上排为真实测试样本，下排为同一个条件模型在不同标签下生成的样本。

表 5: 条件 DDPM 在四类分布上的生成质量，均为 3 个随机种子的均值 $\pm$ 标准差。

数据集	MMD $\downarrow$	SWD $\downarrow$	Precision $\uparrow$	Coverage $\uparrow$
Gaussian Mixture	0.0022 ± 0.0010	0.095 ± 0.016	0.831 ± 0.017	0.946 ± 0.009
Ring	0.0029 ± 0.0028	0.090 ± 0.037	0.876 ± 0.004	0.993 ± 0.003
Two Moons	0.0014 ± 0.0008	0.072 ± 0.018	0.741 ± 0.019	0.959 ± 0.011
Spiral	0.0025 ± 0.0005	0.099 ± 0.008	0.821 ± 0.004	0.960 ± 0.015

图 4 和表 5 表明，一个统一条件模型可以根据标签生成四类分布，完成了题目拓展任务中的条件生成要求。不过，与单独训练的 DDPM 相比，条件 DDPM 在 Gaussian Mixture、Ring 和 Spiral 上的 MMD 更高，说明多分布共享参数会引入一定干扰。Two Moons 上条件 DDPM 与单独 DDPM 的 MMD 接近，说明该结构对月牙形几何仍能较好表达。

8 八、超参数与鲁棒性分析

8.1 KDE 带宽与 GMM 组分数




图 5: KDE 带宽和 GMM 组分数的扫描结果。KDE 使用验证 NLL 选带宽，GMM 使用 BIC 选组分数。

图 5 展示了经典模型的关键超参数影响。KDE 带宽过小时会产生过多局部尖峰，带宽过大则会抹平 Ring 的中心空洞和 Spiral 的细节；GMM 组分数过少时无法拟合弯曲结构，组分数过多又会增加复杂度，因此 BIC 在拟合能力和复杂度之间做折中。

8.2 异常点鲁棒性




图 6: 向训练集中加入不同比例均匀异常点后, 四类模型的 MMD 变化。曲线为 3 个随机种子的均值, 误差棒为标准差。

异常点实验表明, 四类模型都会受到训练污染影响, 但影响方式不同。KDE 会在异常点附近放置核函数, 从而抬高低密度区域的估计密度; GMM 可能分配额外成分解释异常点, 导致有效组分被浪费; VAE 和 DDPM 则可能把异常点吸收到平滑生成分布中, 表现为 Precision 或 MMD 的退化。由于鲁棒性实验也使用 3 个随机种子重复, 图 6 的误差棒可以反映污染实验的不稳定性。这个结果说明, 即使某个模型在干净数据上表现很好, 也不能忽略训练数据质量对生成分布的影响。

9 九、讨论与局限

9.1 为什么经典模型表现很强

本实验中 KDE 和 GMM 的表现并不意外。本文使用的数据只有二维, 训练样本达到 1200 个, 且测试分布和训练分布来自同一机制。此时非参数估计和混合高斯都有足够数据覆盖支撑区域。相比之下, VAE 和 DDPM 的神经网络结构需要通过优化学习密度形状, 在这种低维合成任务上不一定比直接利用样本邻域更有效。因此, 本文结论应理解为“在当前二维设置下经典模型是强基线”, 而不是“经典模型普遍优于神经生成模型”。

9.2 VAE 的过平滑现象

VAE 在四类数据上 Precision 明显偏低，说明生成样本常落在真实支撑之外。原因在于标准正态潜空间和均方重构误差倾向于学习连续平滑映射。当真实分布具有空洞或窄流形时，VAE 容易在流形之间插值，产生视觉上“填充空白”的样本。这个现象在 Ring 和 Two Moons 上最明显。

9.3 DDPM 的优势与成本

DDPM 长训练后在 Spiral 上取得最低 MMD，说明逐步去噪模型能学习复杂非线性结构。但它仍需要更长训练和多步采样，训练时间约为 KDE 的几十倍。对二维课程作业而言，DDPM 的价值更多在于展示现代生成模型思想和复杂几何表达能力，而不是在所有指标上压倒经典方法。

9.4 局限性

本文仍有若干局限：

1. 数据由本地脚本模拟生成，而不是助教真实文件；若后续获得官方数据，应替换数据源后重新运行；
2. VAE 和 DDPM 没有做大规模超参数搜索，因此神经模型可能不是最优实现；
3. 本文没有实现 RealNVP 等精确似然神经模型，NLL 比较只覆盖 KDE 和 GMM；
4. Precision/Coverage 的半径选择依赖近邻距离，改变半径会影响绝对数值；二维网格支撑覆盖率也受网格分辨率影响；
5. 二维合成任务不能直接说明高维图像生成中的模型优劣。

10 十、结论

本文完成了二维分布生成建模任务，并比较了 KDE、GMM、VAE 和 DDPM 四类模型。主要结论如下：

1. 在当前二维合成数据和样本量设置下，KDE 和 GMM 是非常强的基线，不应被省略；
2. Gaussian Mixture 最符合 GMM 的假设，因此 GMM 取得最低 MMD 和 SWD；
3. Ring 上 KDE 表现最好，说明局部核平滑能自然保持闭合支撑；
4. Two Moons 可被多个局部高斯成分较好逼近，因此 GMM 在 MMD/SWD 上领先；
5. Spiral 上 DDPM 取得最低 MMD，体现了逐步去噪模型对复杂曲线支撑的优势，但其局部 Precision 仍有提升空间；

6. VAE 在本设置中明显过平滑，生成样本容易进入低密度区域；
7. 条件 DDPM 可以用一个模型按标签生成四类分布，但共享参数会带来一定性能损失；
8. 多个评价指标会给出不同侧面的结论，因此生成模型评价必须结合可视化、MMD/SWD、Precision/Coverage、支撑覆盖率和 NLL。

如果继续改进，最有价值的方向是加入 RealNVP 或 Neural Spline Flow 作为精确似然神经模型，并在官方数据上重新评估。这样可以在保持神经模型表达能力的同时，对 NLL 做更公平的横向比较。

11 十一、复现实验、分工与 AI 使用说明

11.1 复现实验

在项目根目录运行：

```
MPLCONFIGDIR=/tmp/mplconfig XDG_CACHE_HOME=/tmp \  
python final_project/src/run_experiments.py \  
  --out-dir final_project/results \  
  --n-train 1200 --n-test 900 --n-generate 900 \  
  --seeds 0 1 2 --vae-epochs 320 --ddpm-epochs 2500 --ddpm-steps 100
```

本次运行环境如下：Python 3.12.7, NumPy 1.26.4, SciPy 1.13.1, scikit-learn 1.5.1, PyTorch 2.5.1, Matplotlib 3.9.2, macOS 15.3.1, CPU 运行。完整记录见运行清单：[final_project/results/run_manifest.json](#)。

11.2 文件清单

文件或目录	说明
src/run_experiments.py	数据生成、模型训练、评价与绘图脚本
results/metrics_summary.csv	聚合指标表
results/metrics_by_seed.json	逐 seed 完整指标
results/conditional_metrics_summary.csv	条件 DDPM 聚合指标
results/robustness.csv	多模型异常点鲁棒性指标
results/figures/	报告使用的 PDF/PNG 图像
results/tables/	LaTeX 表格片段
report/main.tex	本报告源码
report/main.pdf	编译后的报告 PDF

11.3 分工情况

本次作业为独立完成。分工记录如下：模型方案设计、代码实现、实验运行、图表制作、论文撰写、结果核验和最终排版均由孙悦淳完成。

11.4 AI 使用说明

AI 工具用于辅助规划报告结构、整理实验代码、检查叙事逻辑和排版细节。所有实验数据、指标数值和图像均由本地脚本实际运行生成，未手工编造。最终结论根据 `metrics_summary.csv`、图

像文件和运行清单核对后写入报告。

A 附录 A：关键实现片段

以下片段展示了 MMD 的核心计算逻辑：

```
def mmd_rbf(x, y):
    z = np.vstack([x, y])
    sample = z[rng.choice(len(z), size=min(600, len(z)), replace=False)]
    sigma2 = np.median(pairwise_sq_dists(sample, sample))
    kxx = np.exp(-pairwise_sq_dists(x, x) / (2 * sigma2)).mean()
    kyy = np.exp(-pairwise_sq_dists(y, y) / (2 * sigma2)).mean()
    kxy = np.exp(-pairwise_sq_dists(x, y) / (2 * sigma2)).mean()
    return max(kxx + kyy - 2 * kxy, 0.0)
```

B 附录 B：结论验证表

表 7: 主要结论与证据对应关系

结论	证据	判定
经典模型在二维任务中很强	KDE/GMM 在多数数据集 MMD/SWD 最低	支持
VAE 存在过平滑	Ring/Two Moons 可视化和低 Precision	支持
DDPM 适合复杂螺旋支撑但局部仍不稳	Spiral 上 MMD 最低但 Precision 低于 KDE/GMM	支持
条件生成可行但有性能代价	条件 DDPM 可生成四类分布但部分 MMD 高于独立模型	支持
单一指标不足	MMD、Coverage、Precision 排名不完全一致	支持
异常点会影响生成质量	四类模型 Robustness 曲线随 outlier rate 变化	支持

参考文献

- [1] D. P. Kingma and M. Welling. Auto-Encoding Variational Bayes. International Conference on Learning Representations, 2014.
- [2] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. International Conference on Machine Learning, 2015.
- [3] J. Ho, A. Jain, and P. Abbeel. Denoising Diffusion Probabilistic Models. Advances in Neural Information Processing Systems, 2020.

- [4] L. Dinh, J. Sohl-Dickstein, and S. Bengio. Density Estimation using Real NVP. International Conference on Learning Representations, 2017.
- [5] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Scholkopf, and A. Smola. A Kernel Two-Sample Test. Journal of Machine Learning Research, 2012.
- [6] M. Arjovsky, S. Chintala, and L. Bottou. Wasserstein Generative Adversarial Networks. International Conference on Machine Learning, 2017.
- [7] T. Kynkaanniemi, T. Karras, S. Laine, J. Lehtinen, and T. Aila. Improved Precision and Recall Metric for Assessing Generative Models. Advances in Neural Information Processing Systems, 2019.
- [8] scikit-learn developers. Density Estimation and Gaussian Mixture Models User Guide. <https://scikit-learn.org/stable/modules/density.html>, <https://scikit-learn.org/stable/modules/mixture.html>.