

期末大作业实验报告

二维复杂分布生成建模的比较研究

孙悦淳 王睿成 孙庄齐

2026 年 6 月 10 日

摘要

本报告选择期末大作业的“二维分布生成建模”选题，研究不同生成模型在 Gaussian Mixture、Ring、Two Moons 和 Spiral 四类二维复杂分布上的建模能力。二维数据虽然维度低，但仍包含多峰、闭合支撑、弯曲流形和螺旋结构等难点，容易暴露模式遗漏、过平滑和离流形采样等问题。我们从数学建模角度将任务表述为学习未知分布 $p_c(\mathbf{x})$ 并从中采样的问题，并比较核密度估计 (KDE)、高斯混合模型 (GMM)、变分自编码器 (VAE) 和去噪扩散概率模型 (DDPM) 四类方法。

实验使用题目提供的 `distribution2d_gen/generate_data.py` 生成四类训练集和测试集，每类训练样本 2000 个、测试样本 2000 个，并在 3 个随机种子上重复训练与采样。评价指标包括负对数似然 (NLL)、最大均值差异 (MMD)、切片 Wasserstein 距离 (SWD)、Precision、Coverage 和二维网格支撑覆盖率。结果显示，在官方二维生成器和当前样本量设置下，KDE 是最稳定的基线：它在四类分布上均取得最低 MMD、最低 SWD 和最高 Coverage；GMM 在 Gaussian Mixture、Ring 和 Two Moons 上具有较高 Precision 与较低 NLL，但在 Spiral 上受椭圆高斯局部假设限制；DDPM 在 Ring 和 Two Moons 上能生成大致形状，但在 Spiral 上仍明显偏散；VAE 训练稳定，但生成样本过于平滑。我们还完成了条件 DDPM、超参数扫描和四类模型的异常点鲁棒性实验。整体来看，在这个低维合成任务上，模型新旧不是最重要的，模型假设是否贴合数据形状更关键。

关键词：生成模型；二维分布；核密度估计；高斯混合模型；变分自编码器；扩散模型；MMD；Wasserstein 距离

一、问题的提出

1.1 任务背景

生成建模的目标是从训练样本中学习数据背后的概率分布，并从该分布中生成新的样本。与分类和回归任务不同，生成建模关心的是整组样本是否合理：是否覆盖真实分布的支撑，是否遗漏模式，是否把点生成到低密度区域。

本次期末大作业给定四类二维复杂分布：Gaussian Mixture、Ring、Two Moons 和 Spiral。设第 c 类训练数据为

$$D_c = \{\mathbf{x}_i^{(c)}\}_{i=1}^{N_c}, \quad \mathbf{x}_i^{(c)} \in \mathbb{R}^2, \quad c = 1, 2, 3, 4.$$

任务是在训练集上建立生成模型，并在测试集上评价生成质量。由于样本是二维点，模型结果可以直接可视化，适合分析模型假设和数据几何结构之间是否匹配。

1.2 核心问题

本报告围绕以下核心问题展开：

不同生成模型的结构假设，分别适合哪些二维几何分布？

具体而言，Gaussian Mixture 主要考验多峰建模；Ring 考验模型是否能保持中心低密度空洞；Two Moons 考验模型是否能表示非凸且分离的弯曲支撑；Spiral 考验模型对长程螺旋结构的表达能力。如果模型只生成一团点，就不能说它学到了分布结构。

1.3 实验任务

本报告完成以下实验任务：

1. 使用题目提供的数据生成代码构造四类二维分布数据集，并对其几何结构和建模难点进行分析；
2. 实现 KDE、GMM、VAE 和 DDPM 四类生成模型；
3. 使用 MMD、切片 Wasserstein 距离、Precision、Coverage、支撑覆盖率和 NLL 评价生成质量；
4. 对 KDE 带宽和 GMM 组分数进行超参数扫描；
5. 实现一个统一的条件 DDPM $p_\theta(\mathbf{x} | c)$ ，根据类别标签生成指定分布；
6. 设计异常点污染实验，比较 KDE、GMM、VAE 和 DDPM 的鲁棒性；
7. 生成图表、指标文件、复现脚本和运行环境清单。

二、实验方法

2.1 经典密度估计

KDE 是一种非参数密度估计方法，通过在每个训练样本附近放置核函数来近似整体分布。它不需要假设数据来自有限个参数化分布，适合二维、小样本、可视化任务；缺点是带宽 h 对结果影响很大，过小会产生噪声尖峰，过大会抹平真实结构。GMM 假设分布可以表示为多个高斯分布的加权和，并通过 EM 算法估计参数。GMM 适合多峰数据，也可以用多个局部高斯去拼接曲线结构；但每个成分仍是椭圆型高斯。

2.2 神经生成模型

VAE 将生成过程写成潜变量模型，利用编码器和解码器最大化证据下界 (ELBO) [1]。它提供了清晰的概率建模解释，也易于训练；但标准高斯先验与均方重构损失容易导致过平滑，特别是在真实分布位于低维弯曲流形附近时。

DDPM 通过逐步加噪和逐步去噪学习生成过程 [2, 3]。与一次性从潜变量解码不同，扩散模型把生成过程拆成许多小的去噪步骤。在二维问题中，这个过程可以直接画出来：样本从高斯噪声逐步收缩到目标分布附近。不过 DDPM 训练和采样都更慢，训练不足时也容易留下散点。

2.3 评价指标

生成模型评价不能只看单个指标。NLL 衡量模型对测试样本赋予的密度，但只适用于可计算密度的模型；MMD 来自核两样本检验 [5]，可比较两组样本的整体分布差异；Wasserstein 类距离关注从一个分布搬运到另一个分布的代价 [6]；Precision 和 Coverage 分别描述生成样本质量和真实样本覆盖情况 [7]。因此我们同时报告这些指标，不只看一个分数。

三、数据、假设与符号说明

3.1 数据生成与预处理

数据来自题目提供的二维分布生成代码 `distribution2d_gen/generate_data.py`。官方脚本默认每类生成 2000 个训练样本、2000 个测试样本和 2000 个隐藏测试样本，并保存 `train.npy`、`test.npy`、标签文件和 `metadata.json`。主实验使用训练集拟合模型、测试集评价生成质量；为估计随机性，实验脚本复刻官方生成机制，并在不同随机种子下重新生成训练集和测试集。四类分布的构造如下：

- Gaussian Mixture: 8 个等角度分布在半径 2.6 圆周上的高斯模式，噪声标准差为 0.16；
- Ring: 半径约为 2.2 的闭合圆环，带径向噪声和小幅切向扰动；

- Two Moons: 上下两条月牙曲线，加入高斯噪声后整体缩放和平移；
- Spiral: 双臂螺旋结构，半径随角度增长，并加入高斯噪声。

所有模型使用训练集均值和标准差进行标准化：

$$\tilde{\mathbf{x}} = \frac{\mathbf{x} - \boldsymbol{\mu}_{\text{train}}}{\boldsymbol{\sigma}_{\text{train}}}.$$

测试集和生成样本的评价均在标准化空间中完成，图像也使用同一坐标尺度展示。




图 1: 四类二维测试分布。Gaussian Mixture 呈现离散多峰结构；Ring 具有中心空洞；Two Moons 是两个弯曲月牙；Spiral 具有长程螺旋支撑。

3.2 建模假设

我们采用如下假设：

1. 训练样本和测试样本均独立同分布地来自未知真实分布 $p_c(\mathbf{x})$ ；
2. 四类分布之间相互独立，主实验分别为每类数据训练一个无条件模型；
3. 训练集只用于拟合模型与选择超参数，测试集只用于最终评价；

4. 生成样本数与测试样本数相同，均为每类 2000；
5. 每个模型在随机种子 0, 1, 2 上重复运行，并报告均值和标准差。

3.3 符号说明

表 1: 主要符号说明

符号	含义	维度或取值
$\mathbf{x}$	二维样本点	$\mathbb{R}^2$
D_c	第 c 类训练样本集合	有限集合
$p_c(\mathbf{x})$	第 c 类真实数据分布	概率密度
$\hat{p}_\theta(\mathbf{x})$	模型学习到的分布	概率密度或隐式分布
$\mathbf{z}$	VAE 潜变量	$\mathbb{R}^2$
t	DDPM 扩散时间步	$1, \dots, T$
ϵ_θ	DDPM 噪声预测网络	$\mathbb{R}^2 \times \{1, \dots, T\} \rightarrow \mathbb{R}^2$
X, Y	测试样本集与生成样本集	点集

四、数学模型建立

4.1 核密度估计

KDE 将未知密度估计为

$$\hat{p}_h(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i),$$

其中 K_h 是带宽为 h 的高斯核。我们通过验证负对数似然选择带宽：

$$h^* = \arg \min_h \left[-\frac{1}{m} \sum_{j=1}^m \log \hat{p}_h(\mathbf{x}_j^{\text{val}}) \right].$$

KDE 不需要训练神经网络。在二维且样本覆盖充分时，它往往很强；但它很依赖带宽，高维扩展也不方便。

4.2 高斯混合模型

GMM 假设

$$\hat{p}(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k), \quad \sum_{k=1}^K \pi_k = 1.$$

参数 $\{\pi_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}$ 由 EM 算法估计。组分数 K 通过 BIC 选择：

$$\text{BIC} = -2 \log L + \nu \log n,$$

其中 L 为最大似然， ν 为参数个数。BIC 惩罚模型复杂度，避免用过多高斯成分机械记忆训练样本。

4.3 变分自编码器

VAE 假设潜变量满足 $\mathbf{z} \sim \mathcal{N}(0, I)$ ，解码器给出 $p_\theta(\mathbf{x} | \mathbf{z})$ 。由于真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ 难以计算，引入编码器 $q_\phi(\mathbf{z} | \mathbf{x})$ ，最大化 ELBO：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x})} [\log p_\theta(\mathbf{x} | \mathbf{z})] - D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})).$$

我们的实现采用二维潜变量、两层 SiLU MLP 编码器和解码器，训练损失写为重构误差加 KL 正则：

$$\mathcal{L}_{\text{VAE}} = \|\hat{\mathbf{x}} - \mathbf{x}\|_2^2 + \beta D_{\text{KL}}.$$

4.4 去噪扩散概率模型

DDPM 的前向过程逐步向数据加入高斯噪声：

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) I),$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。训练时随机采样时间步 t 和噪声 ϵ ，构造

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon,$$

并训练网络预测噪声：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{\mathbf{x}_0, t, \epsilon} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2.$$

采样时从标准高斯噪声出发，按反向过程逐步去噪得到 $\mathbf{x}_0$ 的样本。我们使用 100 个扩散步和 2500 轮训练。这个设置在 CPU 上可以运行，效果和时间开销都还可接受。

五、评价指标

5.1 负对数似然

对显式密度模型，测试集 NLL 定义为

$$\text{NLL} = -\frac{1}{m} \sum_{j=1}^m \log \hat{p}_\theta(\mathbf{x}_j).$$

KDE 和 GMM 可直接计算 NLL。VAE 和 DDPM 的严格似然估计需要额外近似，因此我们没有把它们放进同一个 NLL 比较表。

5.2 最大均值差异

MMD 衡量两组样本在再生核 Hilbert 空间中的均值嵌入差异：

$$\text{MMD}^2(X, Y) = \frac{1}{m^2} \sum_{i,j} k(x_i, x_j) + \frac{1}{n^2} \sum_{i,j} k(y_i, y_j) - \frac{2}{mn} \sum_{i,j} k(x_i, y_j).$$

我们使用 RBF 核，并用样本距离的 median heuristic 选择核宽度。MMD 越低，生成分布与测试分布越接近。脚本中实际报告的是 MMD^2 ，但为方便阅读，表格中仍记为 MMD。

5.3 切片 Wasserstein 距离

二维 Wasserstein 距离可以通过多个一维投影近似。对随机方向 $\mathbf{v}$ ，先将样本投影为 $x_i^\top \mathbf{v}$ ，再计算一维排序后的平均距离；对多个方向取平均得到 SWD。SWD 越低，生成样本的整体位置与真实样本越接近。

5.4 Precision、Coverage 与支撑覆盖率

Precision 衡量生成样本是否落在真实数据邻域中，Coverage 衡量真实样本是否被生成样本覆盖。我们用测试集第 k 近邻距离的中位数确定半径 r ，定义

$$\text{Precision} = \frac{1}{|Y|} \sum_{\mathbf{y} \in Y} \mathbb{I}(d(\mathbf{y}, X) \leq r), \quad \text{Coverage} = \frac{1}{|X|} \sum_{\mathbf{x} \in X} \mathbb{I}(d(\mathbf{x}, Y) \leq r).$$

我们还将测试样本所在区域划分为 36×36 的二维网格，统计真实样本占据网格中有多少也被生成样本覆盖，作为支撑覆盖率。该指标比单纯按角度或横坐标分箱更严格，因为它同时约束二维位置和局部几何支撑。

六、实验设计

6.1 实验设置

主实验比较 KDE、GMM、VAE 和 DDPM 四类模型。每个模型在四类数据上分别训练，并在 3 个随机种子上重复。每次实验生成 2000 个新样本，与 2000 个测试样本进行比较。所有结果均由脚本 `src/run_experiments.py` 生成。

表 2: 模型设置

模型	关键参数	训练或选择方式	备注
KDE	带宽 h	验证 NLL 网格搜索	显式密度
GMM	组分数 K	BIC 网格搜索	显式密度
VAE	二维潜变量, MLP 编解码器	AdamW, 320 epochs	隐式采样, 近似概率模型
DDPM	100 扩散步, MLP 噪声网络	AdamW, 2500 epochs	隐式采样
条件 DDPM	100 扩散步, 类别嵌入	AdamW, 1875 epochs	统一条件生成模型

6.2 产物组织

运行后生成如下产物:

- `metrics_by_seed.csv/json`: 逐数据集、逐模型、逐 seed 指标;
- `metrics_summary.csv/json`: 均值和标准差;
- `figures/*.pdf`: 报告图表;
- `tables/*.tex`: 可直接插入报告的表格;
- `conditional_metrics_summary.csv`: 条件 DDPM 指标;
- `robustness.csv`: 异常点鲁棒性实验指标;
- `run_manifest.json`: 运行环境、随机种子、训练轮数和依赖版本。

七、实验结果

7.1 生成样本可视化




图 2: 四类模型在四类二维分布上的生成样本。灰色点为测试样本，蓝色点为生成样本。

KDE/GMM 在当前低维任务中是较强基线；VAE 明显过平滑；DDPM 在 Ring 和 Two Moons 上能生成大致结构，但在 Spiral 上偏散。

图 2 直接显示了模型差异。KDE 在四类数据上的生成样本与测试分布较为贴合；在二维、样本量充分且带宽经过验证选择时，非参数密度估计很有竞争力。GMM 在 Gaussian Mixture、Ring 和 Two Moons 上也较稳定，但在 Spiral 上需要用多个椭圆成分拼接长曲线，局部贴合不如 KDE。VAE 往往把样本填到低密度区域，例如 Ring 的中心区域和 Two Moons 两条月牙之间。DDPM 在 Ring 和 Two Moons 上能生成大致形状，但 Spiral 上明显偏散，局部结构没有贴住真实螺旋。

7.2 主指标对比

表 3: 四类模型在四类分布上的主指标，均为 3 个随机种子的均值 $\pm$ 标准差。NLL 只对 KDE 和 GMM 报告。

数据集	模型	MMD $\downarrow$	SWD $\downarrow$	Precision $\uparrow$	Coverage $\uparrow$	NLL $\downarrow$
Gaussian Mixture	KDE	0.0004 ± 0.0002	0.038 ± 0.006	0.930 ± 0.004	0.967 ± 0.005	0.079 ± 0.012
Gaussian Mixture	GMM	0.0005 ± 0.0002	0.042 ± 0.006	0.962 ± 0.006	0.956 ± 0.002	0.051 ± 0.017
Gaussian Mixture	VAE	0.0105 ± 0.0023	0.188 ± 0.015	0.235 ± 0.007	0.676 ± 0.004	—
Gaussian Mixture	DDPM	0.0009 ± 0.0005	0.061 ± 0.010	0.849 ± 0.009	0.958 ± 0.006	—
Ring	KDE	0.0004 ± 0.0004	0.035 ± 0.012	0.963 ± 0.007	0.988 ± 0.005	1.200 ± 0.002
Ring	GMM	0.0006 ± 0.0003	0.043 ± 0.009	0.978 ± 0.005	0.983 ± 0.003	1.167 ± 0.008
Ring	VAE	0.0103 ± 0.0019	0.172 ± 0.015	0.586 ± 0.026	0.904 ± 0.012	—
Ring	DDPM	0.0013 ± 0.0006	0.060 ± 0.012	0.957 ± 0.004	0.986 ± 0.002	—
Two Moons	KDE	0.0002 ± 0.0001	0.030 ± 0.004	0.960 ± 0.009	0.987 ± 0.006	1.660 ± 0.030
Two Moons	GMM	0.0003 ± 0.0002	0.035 ± 0.009	0.973 ± 0.008	0.977 ± 0.003	1.654 ± 0.040
Two Moons	VAE	0.0059 ± 0.0017	0.154 ± 0.012	0.519 ± 0.011	0.935 ± 0.007	—
Two Moons	DDPM	0.0022 ± 0.0013	0.082 ± 0.025	0.840 ± 0.009	0.967 ± 0.006	—
Spiral	KDE	0.0006 ± 0.0004	0.047 ± 0.013	0.963 ± 0.001	0.989 ± 0.001	2.165 ± 0.009
Spiral	GMM	0.0008 ± 0.0005	0.061 ± 0.013	0.813 ± 0.009	0.955 ± 0.002	2.549 ± 0.023
Spiral	VAE	0.0014 ± 0.0004	0.083 ± 0.003	0.721 ± 0.003	0.914 ± 0.002	—
Spiral	DDPM	0.0008 ± 0.0008	0.078 ± 0.015	0.725 ± 0.016	0.945 ± 0.010	—

表 4: 按指标选出的最佳模型

数据集	最低 MMD	最低 SWD	最高 Coverage
Gaussian Mixture	KDE	KDE	KDE
Ring	KDE	KDE	KDE
Two Moons	KDE	KDE	KDE
Spiral	KDE	KDE	KDE

表 3 和表 4 给出定量结果。Gaussian Mixture 上，KDE 的 MMD 为 0.0004 ± 0.0002 ，略低于 GMM；但 GMM 的 NLL 更低、Precision 更高，对测试点赋予更高似然。Ring 上，KDE 的 MMD、SWD 和 Coverage 均为最优，Coverage 达到 0.988 ± 0.005 ，合适带宽的局部核函数可以保持闭合支撑。Two Moons 上，KDE 仍取得最低 MMD 与 SWD，GMM 依靠多个局部高斯获得最高 Precision。Spiral 上，KDE 的 MMD 为 0.0006 ± 0.0004 ，低于 GMM 和 DDPM；DDPM 与 GMM 的 MMD 接近，但 Precision 只有 0.725 ± 0.016 ，它在整体距离上接近 GMM，但生成点仍

有不少落在螺旋支撑之外。

7.3 指标热力图




图 3: 每个数据集内部按 MMD 归一化后的相对排名。颜色越绿表示 MMD 越低。

图 3 中，KDE 在官方二维数据和 2000 个训练样本设置下排名最稳定。这并不代表 KDE 在所有生成任务中都优于神经模型。更准确地说，当数据维度低、样本量足够、测试分布和训练分布来自同一机制时，直接利用样本邻域的非参数估计效果很强。低维生成任务不能简单按模型新旧排序，还要看数据形状和评价指标。

7.4 条件生成实验

除分别为每类数据训练无条件模型外，我们还实现了一个统一的条件 DDPM。该模型在输入中加入类别嵌入，学习

$$p_{\theta}(\mathbf{x} | c), \quad c \in \{\text{Gaussian Mixture, Ring, Two Moons, Spiral}\}.$$

训练时将四类训练样本合并，并用类别标签控制反向去噪过程；采样时指定类别 c ，生成对应分布的样本。由于四类数据是在各自标准化空间中合并训练的，该模型更适合作为条件生成演示，而不是严格的统一原始坐标系密度模型。




图 4: 统一条件 DDPM 的按类别生成结果。上排为真实测试样本，下排为同一个条件模型在不同标签下生成的样本。

表 5: 条件 DDPM 在四类分布上的生成质量，均为 3 个随机种子的均值 $\pm$ 标准差。

数据集	MMD $\downarrow$	SWD $\downarrow$	Precision $\uparrow$	Coverage $\uparrow$
Gaussian Mixture	0.0020 ± 0.0005	0.094 ± 0.001	0.514 ± 0.056	0.941 ± 0.011
Ring	0.0025 ± 0.0016	0.086 ± 0.029	0.909 ± 0.013	0.981 ± 0.002
Two Moons	0.0019 ± 0.0014	0.084 ± 0.025	0.763 ± 0.018	0.966 ± 0.003
Spiral	0.0031 ± 0.0005	0.111 ± 0.009	0.729 ± 0.013	0.938 ± 0.015

图 4 和表 5 可以看出，类别标签确实起到了控制作用，但质量并不均衡。Ring 较清楚，Two Moons 能看出月牙轮廓；Gaussian Mixture 被拉成近似环状，Spiral 仍偏散。与单独训练的 DDPM 相比，条件 DDPM 在 Gaussian Mixture、Ring 和 Spiral 上的 MMD 更高，多分布共享参数带来了干扰。

八、超参数与鲁棒性分析

8.1 KDE 带宽与 GMM 组分数




图 5: KDE 带宽和 GMM 组分数的扫描结果。KDE 使用验证 NLL 选带宽，GMM 使用 BIC 选组分数。

图 5 给出了经典模型的超参数扫描。KDE 带宽过小时会产生过多局部尖峰，带宽过大则会抹平 Ring 的中心空洞和 Spiral 的细节；GMM 组分数过少时无法拟合弯曲结构，组分数过多又会增加复杂度，因此 BIC 在拟合能力和复杂度之间做折中。Gaussian Mixture 的 KDE 带宽选到网格下界，Spiral 的 GMM 组分数选到 $K = 20$ ，这两个搜索网格还可以继续放宽。

8.2 异常点鲁棒性




图 6: 向训练集中加入不同比例均匀异常点后, 四类模型的 MMD 变化。曲线为 3 个随机种子的均值, 误差棒为标准差。

异常点实验显示, 训练污染会改变各模型的采样分布, 但影响方式不同。KDE 会在异常点附近放置核函数, 从而抬高低密度区域的估计密度; GMM 可能分配额外成分解释异常点, 导致有效组分被浪费; VAE 和 DDPM 可能把异常点吸收到平滑生成分布中。图 6 的曲线并非严格单调, 尤其是神经模型在部分污染率下有明显波动。干净数据上的排名不能直接代表污染数据上的表现。

九、讨论与局限

9.1 经典模型效果更好的原因

KDE 和 GMM 在这里表现好, 主要是因为数据只有二维, 每类还有 2000 个训练点。此时非参数估计和混合高斯都有足够数据覆盖支撑区域。尤其是 KDE, 它没有强加有限高斯成分假设, 只需通过带宽控制局部平滑, 因此在 Ring、Two Moons 和 Spiral 这类弯曲支撑上也能保持很高 Coverage。相比之下, VAE 和 DDPM 需要通过优化学习密度形状, 在这种低维合成任务上不一定比直接利用样本邻域更有效。因此, 在当前二维设置下经典模型是强基线, 但这不能外推为经典模型普遍优于神经生成模型。

9.2 VAE 的过平滑现象

VAE 在四类数据上 Precision 明显偏低，生成样本常落在真实支撑之外。标准正态潜空间和均方重构误差会鼓励连续平滑的映射。当真实分布有空洞或窄流形时，VAE 容易在流形之间插值，在低密度空白区域生成样本。Ring 和 Two Moons 上最容易看到这个问题。

9.3 DDPM 的表达能力和成本

DDPM 长训练后可以生成 Ring 和 Two Moons 的大致结构，但 Spiral 仍然偏散。逐步去噪模型具备表达非线性几何的能力，只是当前网络规模和训练预算还不够稳。它也需要更长训练和多步采样，训练时间约为 KDE 的十倍以上。在本次实验里，DDPM 更像是一个现代生成模型对照项：它能说明扩散建模的思路，但指标上不是最优模型。

9.4 局限性

本次实验还有几处局限：

1. 数据来自题目提供的二维合成生成器，结论只对应该生成机制，不能外推到真实高维数据；
2. VAE 和 DDPM 没有做大规模超参数搜索，因此神经模型可能不是最优实现；
3. Precision/Coverage 的半径选择依赖近邻距离，改变半径会影响绝对数值，二维网格支撑覆盖率也受网格分辨率影响；
4. 二维合成任务不能直接说明高维图像生成中的模型优劣。

十、结论

我们完成了二维分布生成建模实验，并比较了 KDE、GMM、VAE 和 DDPM 四类模型。主要结论如下：

1. 在给定的二维生成器和每类 2000 个训练样本设置下，KDE 是最稳定的基线，在四类分布上均取得最低 MMD、最低 SWD 和最高 Coverage；
2. Gaussian Mixture 上 GMM 的 NLL 和 Precision 最好，但 KDE 的样本分布距离更低，说明密度拟合和样本匹配并不完全等价；
3. Ring 和 Two Moons 上 KDE 表现最好，说明局部核平滑能自然保持闭合或弯曲支撑；
4. Spiral 上 KDE 仍取得最低 MMD，GMM 与 DDPM 接近但 Precision 较低，说明长曲线支撑对局部贴合要求更高；
5. VAE 在本设置中明显过平滑，生成样本容易进入低密度区域；

6. 条件 DDPM 可以用一个模型按标签生成不同分布，但 Gaussian Mixture 和 Spiral 的结果还不够好，共享参数会带来一定性能损失；
7. 多个评价指标会给出不同侧面的结论，因此生成模型评价需要结合可视化、MMD/SWD、Precision/Coverage、支撑覆盖率和 NLL。

对于改进方向，可以考虑加入 RealNVP 或 Neural Spline Flow 作为精确似然神经模型。这样可以在保持神经模型表达能力的同时，对 NLL 做更公平的横向比较，也能检验神经生成模型是否能在二维官方数据上同时取得好样本距离和好似然。

十一、复现实验、分工与 AI 使用说明

11.1 复现实验

在项目根目录运行：

```
python distribution2d_gen/generate_data.py \  
    --output-dir data --plot  
  
MPLCONFIGDIR=/tmp/mplconfig XDG_CACHE_HOME=/tmp \  
python src/run_experiments.py \  
    --out-dir results \  
    --n-train 2000 --n-test 2000 --n-generate 2000 \  
    --seeds 0 1 2 --vae-epochs 320 --ddpm-epochs 2500 --ddpm-steps 100
```

本次运行环境如下：Python 3.12.7, NumPy 1.26.4, SciPy 1.13.1, scikit-learn 1.5.1, PyTorch 2.5.1, Matplotlib 3.9.2, macOS 15.3.1, CPU 运行。

11.2 文件清单

文件或目录	说明
distribution2d_gen/generate_data.py	题目提供的二维分布数据生成代码
data/	官方生成器默认 seed 生成的 train/test/hidden 数据文件
src/run_experiments.py	数据生成、模型训练、评价与绘图脚本
results/metrics_summary.csv	聚合指标表
results/metrics_by_seed.json	逐 seed 完整指标
results/conditional_metrics_summary.csv	条件 DDPM 聚合指标
results/robustness.csv	多模型异常点鲁棒性指标
results/figures/	报告使用的 PDF/PNG 图像
results/tables/	LaTeX 表格片段
report/main.tex	本报告源码
report/main.pdf	编译后的报告 PDF

11.3 分工情况

1. 孙庄齐：问题分析，数据生成和预处理，整理题目要求，并分析 Gaussian Mixture、Ring、Two Moons 和 Spiral 的几何结构、噪声特征；
2. 孙悦淳：生成模型建立与实验实现部分，包括实现 KDE、GMM、VAE 和 DDPM 四类生成模型，完成模型训练、样本生成、条件 DDPM 拓展实验，以及相关超参数设置和复现实验脚本整理；
3. 王睿成：评价指标，结果分析，报告撰写，汇报工作，实现了 MMD、Sliced Wasserstein Distance、Precision、Coverage、NLL 和支撑覆盖率等评价指标，完成主实验结果对比、超参数影响分析、鲁棒性分析、图表整理和最终报告排版。

11.4 AI 使用说明

AI 工具用于辅助整理报告结构、检查文字表达和排版细节。实验数据、指标数值和图像均由本地脚本运行生成，没有手工编造。最终结论根据 `metrics_summary.csv`、图像文件和运行清单核对后写入报告。

1. AI 帮助整理了数学建模报告的章节结构和 $\text{\LaTeX}$ 排版；
2. AI 辅助检查了问题提出、实验方法和结果讨论部分的文字；
3. AI 帮助核对了图表说明、文件清单和复现实验命令；
4. 代码、实验运行、结果判断和最终取舍由小组成员完成。

附录：MMD 核心计算逻辑

以下片段给出 MMD 的核心计算逻辑：

```
def mmd_rbf(x, y):
    z = np.vstack([x, y])
    rng = np.random.default_rng(0)
    sample = z[rng.choice(len(z), size=min(600, len(z)), replace=False)]
    d = pairwise_sq_dists(sample, sample)
    sigma2 = np.median(d[d > 0])
    kxx = np.exp(-pairwise_sq_dists(x, x) / (2 * sigma2)).mean()
    kyy = np.exp(-pairwise_sq_dists(y, y) / (2 * sigma2)).mean()
    kxy = np.exp(-pairwise_sq_dists(x, y) / (2 * sigma2)).mean()
    return max(kxx + kyy - 2 * kxy, 0.0)
```

参考文献

- [1] D. P. Kingma and M. Welling. Auto-Encoding Variational Bayes. International Conference on Learning Representations, 2014.
- [2] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. International Conference on Machine Learning, 2015.
- [3] J. Ho, A. Jain, and P. Abbeel. Denoising Diffusion Probabilistic Models. Advances in Neural Information Processing Systems, 2020.
- [4] L. Dinh, J. Sohl-Dickstein, and S. Bengio. Density Estimation using Real NVP. International Conference on Learning Representations, 2017.
- [5] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Scholkopf, and A. Smola. A Kernel Two-Sample Test. Journal of Machine Learning Research, 2012.
- [6] M. Arjovsky, S. Chintala, and L. Bottou. Wasserstein Generative Adversarial Networks. International Conference on Machine Learning, 2017.
- [7] T. Kynkaanniemi, T. Karras, S. Laine, J. Lehtinen, and T. Aila. Improved Precision and Recall Metric for Assessing Generative Models. Advances in Neural Information Processing Systems, 2019.
- [8] scikit-learn developers. Density Estimation and Gaussian Mixture Models User Guide. <https://scikit-learn.org/stable/modules/density.html>, <https://scikit-learn.org/stable/modules/mixture.html>.